

TEMA 1 – IA
MIRCEA BIANCA-ANASTASIA
333CC

3.1. Explorarea Datelor (Exploratory Data Analysis)

1. Analiza tipului de atribute și a plajei de valori a acestora

Pentru inceput, seturile de date au fost incarcate folosind `pandas.read_csv`. Setul de antrenare contine 64000 de exemple si 14 coloane, iar setul de test contine 16000 de exemple si 14 coloane. Prin afisarea primelor randuri din dataset s-a observat ca datele contin atat atribute numerice, cat si atribute categoriale.

```
Train shape: (64000, 14)
Test shape: (16000, 14)
```

	job_title	experience_years	education_level	skills_count	industry	company_size	location	remote_work	certifications	salary	total_days_worked	aggregated_score	skill_bracket	vacation
0	Backend Developer	19	High School	12	Media	Large	USA	Yes	0	203997	4560	-0.723308	mid	Small
1	Backend Developer	4	High School	13	Telecom	Small	Germany	NaN	5	116239	960	-0.481551	high	No Vacation
2	Backend Developer	8	High School	16	Retail	Enterprise	Remote	No	4	145802	1920	-1.533057	high	No Vacation
3	Backend Developer	12	High School	9	Telecom	Enterprise	USA	Hybrid	2	190299	2880	0.527458	mid	Small
4	Backend Developer	14	High School	6	Telecom	Large	UK	Hybrid	4	152679	3360	-0.186280	low	No Vacation

Pentru fiecare coloana a fost calculat numarul de valori lipsa si procentul acestora din totalul dataset-ului. Majoritatea coloanelor nu contin valori lipsa. Singura exceptie observata este coloana `remote_work`, care contine **19153 valori lipsa**, adica aproximativ **29.93%** din setul de antrenare.


	Coloana	Non-Null	Valori lipsa	Procent lipsa (%)	Tip
0	job_title	64000	0	0.000000	str
1	experience_years	64000	0	0.000000	int64
2	education_level	64000	0	0.000000	str
3	skills_count	64000	0	0.000000	int64
4	industry	64000	0	0.000000	str
5	company_size	64000	0	0.000000	str
6	location	64000	0	0.000000	str
7	remote_work	44847	19153	29.926562	str
8	certifications	64000	0	0.000000	int64
9	salary	64000	0	0.000000	int64
10	total_days_worked	64000	0	0.000000	int64
11	aggregated_score	64000	0	0.000000	float64
12	skill_bracket	64000	0	0.000000	str
13	vacation	64000	0	0.000000	str

Pentru atributele numerice au fost calculate statistici descriptive precum numarul de valori nenule, media, deviatia standard, minimul, maximul si procentele de 25%, 50% si 75%.

	count	mean	std	min	25%	50%	75%	max
experience_years	64000.0	9.973391	6.050682	0.000000	5.000000	10.000000	15.000000	20.000000
skills_count	64000.0	11.604047	10.737497	1.000000	5.000000	10.000000	15.000000	69.000000
certifications	64000.0	2.511141	1.709811	0.000000	1.000000	3.000000	4.000000	5.000000
salary	64000.0	145683.565844	37384.755715	31867.000000	119209.750000	143299.000000	169582.250000	333046.000000
total_days_worked	64000.0	2393.508219	1452.044678	-1.000000	1200.000000	2400.000000	3600.000000	4800.000000
aggregated_score	64000.0	0.000929	0.999869	-4.796902	-0.673757	0.001059	0.678273	4.217828

Plaja mare de valori pentru `salary` si `total_days_worked` arata ca aceste coloane pot influenta puternic modelele daca nu sunt standardizate. De asemenea, valorile foarte

mari din salary pot reprezenta outliers, motiv pentru care aceasta coloana trebuie analizata mai atent in etapa urmatoare.




Boxplot-urile evidentiaza plaja de valori pentru fiecare atribut numeric. Se observa valori extreme in special pentru salary si skills_count. Aceste valori pot influenta performanta modelelor, motiv pentru care outlierii vor fi analizati si tratati in etapa de preprocesare.

Pentru attributele categoriale a fost calculat numarul de valori nenule si numarul de valori unice.

	non_null_count	unique_values
job_title	64000	12
education_level	64000	5
industry	64000	10
company_size	64000	5
location	64000	10
remote_work	44847	3
skill_bracket	64000	3
vacation	64000	4

(restul sunt in fisier)



(Graficul arata distributia functiilor din dataset. Valorile pentru job_title sunt relativ echilibrate, ceea ce indica faptul ca nu exista o functie care domina puternic setul de date. Acest atribut este important deoarece poate influenta atat salariul, cat si tipul de vacanta.)

2. Analiza echilibrului de clase

Pentru sarcina de clasificare, variabila tinta este "vacation", care poate lua una dintre cele patru clase: "No Vacation", "Small", "Medium" si "Large".



Graficul arata frecventa de aparitie a fiecărei etichete din sarcina de clasificare. Se observa ca 'No Vacation' este clasa dominanta, in timp ce 'Medium' si 'Large' au un numar considerabil mai mic de exemple.

Pentru a analiza echilibrul claselor, a fost realizat un grafic de frecventa al etichetelor din setul de antrenare. In plus, au fost calculate numarul de exemple si proportia fiecărei clase in totalul dataset-ului.

Rezultatele obtinute arata urmatoarea distributie a claselor:

- No Vacation: 34686 exemple (54.20%)
- Small: 12877 exemple (20.12%)
- Medium: 8527 exemple (13.32%)
- Large: 7910 exemple (12.36%)

Se observa ca setul de date nu este echilibrat. Clasa "No Vacation" este semnificativ mai frecventa decat celelalte clase, avand peste jumatate din totalul exemplilor. Clasele "Medium" si "Large" au un suport mai mic, ceea ce poate face clasificarea mai dificila pentru aceste etichete.


Un astfel de dezechilibru poate afecta evaluarea modelelor de clasificare, deoarece un model poate obtine o acuratete aparent buna daca prezice frecvent clasa majoritara. Din acest motiv, pentru aceasta problema este important sa fie urmarite nu doar acuratetea, ci si metrice precum Precision, Recall si F1-score, care ofera o imagine mai relevanta asupra performantei pe fiecare clasa.

3. Analiza corelației între attribute


Pentru analiza corelației dintre attributele numerice a fost calculata matricea de corelatie Pearson. Aceasta indica masura in care doua variabile numerice variaza impreuna. Valori apropiate de 1 indica o corelatie pozitiva puternica, valori apropiate de -1 indica o corelatie negativa puternica, iar valori apropiate de 0 indica o relatie liniara slaba.

Pentru attributele categoriale a fost utilizat testul Chi-Square, care verifica daca doua variabile categoriale sunt independente sau daca exista o asociere intre ele.


Scopul acestei analize este identificarea eventualelor attribute redundante, dar si observarea relatiei dintre anumite attribute si cele doua sarcini ale temei: clasificarea variabilei `vacation` si regresia variabilei `salary`.



Heatmap-ul arata corelatiile Pearson dintre atributele numerice. Se observa ca anumite variabile, precum `experience_years` si `total_days_worked`, au o relatie pozitiva puternica. De asemenea, `salary` este corelat pozitiv cu unele atribute numerice, ceea ce indica faptul ca acestea pot fi utile pentru sarcina de regresie.




Boxplot-ul arata distributia salariului pentru fiecare clasa a variabilei `vacation`. Se observa ca salariul are o influenta asupra tipului de vacanta, clasele asociate unor vacante mai mari avand in general valori salariale mai ridicate.




Arata frecventa claselor `vacation` pentru fiecare nivel educational. Diferentele dintre distributii sugereaza ca nivelul educational poate avea legatura cu tipul de vacanta.




Testul Chi-Square a indicat un p-value mai mic decat 0.05, ceea ce sugereaza existenta unei relatii semnificative intre `education\_level` si `vacation`.




Graficul evidentiaza relatia dintre variabilele numerice si targetul de regresie `salary`. Atributele cu valori pozitive mai mari ale coeficientului Pearson sunt mai relevante pentru estimarea salariului.



Graficul arata media salariului pentru fiecare nivel educational. Diferentele dintre medii sugereaza ca nivelul educational poate influenta valoarea salariului.



Graficul arata media salariului pentru fiecare functie. Diferentele dintre categorii indica faptul ca `job\_title` este un atribut relevant pentru sarcina de regresie.



Heatmap-ul arata frecventa combinatiilor dintre `job\_title` si `skill\_bracket`. Testul Chi-Square a fost folosit pentru a verifica daca cele doua attribute categoriale sunt independente.

3.2. Preprocesarea datelor

1. Date lipsă pentru un atribut într-un eșantion

În etapa de analiza exploratorie s-a observat ca majoritatea coloanelor nu contin valori lipsa. Singura coloana cu un numar semnificativ de valori lipsa este `remote\_work`.

Coloana `remote\_work` este un atribut categorial, deoarece valorile sale descriu tipul de lucru: remote, on-site sau hybrid. Din acest motiv, nu este potrivita imputarea cu media sau mediana, deoarece aceste metode sunt aplicabile atributelor numerice.

Pentru tratarea valorilor lipsa din `remote\_work` s-a folosit imputarea cu valoarea cea mai frecventa, adica moda. Aceasta metoda este potrivita pentru variabile categoriale, deoarece pastreaza valorile existente in dataset si nu introduce valori artificiale.

	Coloana	Valori lipsa	Procent (%)
7	remote_work	19153	29.93
0	job_title	0	0.00
2	education_level	0	0.00
3	skills_count	0	0.00
4	industry	0	0.00
1	experience_years	0	0.00
5	company_size	0	0.00
6	location	0	0.00
8	certifications	0	0.00
9	salary	0	0.00
10	total_days_worked	0	0.00
11	aggregated_score	0	0.00
12	skill_bracket	0	0.00
13	vacation	0	0.00

Tabelul arata numarul si procentul valorilor lipsa pentru fiecare coloana. Se observa ca `remote\_work` este singura coloana cu valori lipsa semnificative, avand aproximativ 29.93% valori lipsa.

	Coloana	Valori lipsa	Procent (%)
0	job_title	0	0.0
1	experience_years	0	0.0
2	education_level	0	0.0
3	skills_count	0	0.0
4	industry	0	0.0
5	company_size	0	0.0
6	location	0	0.0
7	remote_work	0	0.0
8	certifications	0	0.0
9	salary	0	0.0
10	total_days_worked	0	0.0
11	aggregated_score	0	0.0
12	skill_bracket	0	0.0
13	vacation	0	0.0

Dupa imputarea coloanei `remote\_work` cu valoarea cea mai frecventa, nu mai exista valori lipsa in aceasta coloana. Astfel, dataset-ul poate fi folosit mai departe in etapa de antrenare a modelelor.

2. Valori extreme pentru un atribut într-un eșantion

Pentru identificarea valorilor extreme a fost analizata coloana `salary`, deoarece aceasta are o plaja mare de valori si poate influenta puternic performanta modelelor, mai ales pentru sarcina de regresie.


Outlierii au fost identificati folosind metoda IQR (Interquartile Range). Aceasta metoda foloseste valorile Q1 si Q3, adica percentilele de 25% si 75%. Diferenta dintre ele reprezinta IQR.

O valoare este considerata outlier daca este mai mica decat $Q1 - 1.5 * IQR$ sau mai mare decat $Q3 + 1.5 * IQR$.


Dupa identificarea outlierilor, valorile extreme din coloana `salary` au fost inlocuite cu mediana coloanei. Mediana a fost aleasa deoarece este mai robusta la valori extreme decat media si nu este influentata puternic de salariile foarte mari sau foarte mici.

	Coloana	Q1	Q3	IQR	Limita inferioara	Limita superioara	Nr outlieri	Procent outlieri (%)
0	salary	119209.75	169582.25	50372.5	43651.0	245141.0	587	0.92

Tabelul prezinta valorile Q1, Q3, IQR si limitele folosite pentru detectarea outlierilor. Valorile aflate in afara intervalului $[Q1 - 1.5 * IQR, Q3 + 1.5 * IQR]$ au fost considerate valori extreme.



Boxplot-ul evidentiaza prezenta valorilor extreme in coloana `salary`. Aceste valori pot afecta modelele de regresie, deoarece pot influenta puternic functia de eroare.



Dupa inlocuirea valorilor extreme cu mediana, distributia devine mai stabila, iar impactul outlierilor asupra modelelor este redus.

Prin compararea boxplot-urilor inainte si dupa tratarea outlierilor se observa reducerea valorilor extreme. Aceasta etapa ajuta la obtinerea unor modele mai stabile, mai ales pentru regresie, unde valorile foarte mari ale targetului pot influenta puternic eroarea.



Pentru a verifica daca exista attribute redundante, a fost analizata matricea de corelatie dintre attributele numerice dupa preprocesare. Se observa o corelatie foarte puternica intre `experience\_years` si `total\_days\_worked`, ceea ce indica faptul ca aceste doua coloane contin informatii similare. Totusi, nu a fost eliminata nicio coloana, deoarece attributele pot contribui la performanta modelelor, iar eliminarea lor nu a fost necesara in aceasta etapa.

4. Plaje valorice de mărimi diferite pentru attributele numerice

Atributele numerice din dataset au plaje valorice diferite. De exemplu, `salary` si `total\_days\_worked` au valori mult mai mari decat `certifications`, `skills\_count` sau `aggregated\_score`.

Aceste diferente de scala pot afecta algoritmi liniari, precum Logistic Regression si Linear Regression. In cazul acestor modele, attributele cu valori mari pot domina calculul, chiar daca nu sunt neaparat cele mai importante pentru predictie.

Pentru a evita aceasta problema, a fost aplicata standardizarea atributelor numerice folosind StandardScaler. Prin standardizare, valorile sunt transformate astfel incat fiecare atribut numeric sa aiba media aproximativ 0 si deviatia standard aproximativ 1.

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

numeric_features = X_train.select_dtypes(include=["number"]).columns.tolist()

X_train_encoded[numeric_features] = scaler.fit_transform(X_train_encoded[numeric_features])
X_test_encoded[numeric_features] = scaler.transform(X_test_encoded[numeric_features])

display(X_train_encoded.head())
```

Dupa aplicarea StandardScaler, valorile numerice au fost aduse la o scala comuna, ceea ce ajuta modelele liniare sa invete mai stabil.

3.3 Utilizarea algoritmilor de Învățare Automată

In aceasta etapa au fost antrenate modele de Machine Learning pentru cele doua sarcini ale temei: clasificarea variabilei `vacation` si regresia variabilei `salary`.

Pentru clasificare au fost folosite modelele Decision Tree Classifier si Logistic Regression. Decision Tree a fost folosit ca baseline, iar ulterior au fost realizate experimente prin modificarea hiperparametrului `max\_depth`.

Pentru regresie au fost folosite Linear Regression ca model baseline si Ridge Regression pentru analiza efectului regularizarii. In cazul Ridge Regression a fost variat parametrul `alpha`.

Datele au fost impartite in set de antrenare si set de validare, iar performanta modelelor a fost evaluata pe setul de validare.

	Set	Nr exemple	Nr features
0	Train	51200	46
1	Validation	12800	46

Setul de date a fost impartit in train si validation pentru a evalua performanta modelelor pe date nefolosite la antrenare. Variabila tinta pentru clasificare.

	Model	max_depth	Accuracy	Precision	Recall	F1
0	Decision Tree	5	0.6557	0.5698	0.5333	0.5226

	precision	recall	f1-score	support
Large	0.623	0.674	0.648	1582.000
Medium	0.474	0.119	0.190	1706.000
No Vacation	0.802	0.842	0.822	6937.000
Small	0.379	0.498	0.431	2575.000
accuracy	0.656	0.656	0.656	0.656
macro avg	0.570	0.533	0.523	12800.000
weighted avg	0.651	0.656	0.637	12800.000

Modelul Decision Tree Classifier a fost folosit ca baseline pentru sarcina de clasificare. Acest model imparte datele in functie de attributele care separa cel mai bine clasele. Configuratia initiala a folosit `max\_depth = 5`, pentru a limita complexitatea arborelui si pentru a evita overfitting-ul.


	Model	max_depth	Accuracy	Precision	Recall	F1
0	Decision Tree	3	0.6245	0.3934	0.4378	0.3850
1	Decision Tree	5	0.6557	0.5698	0.5333	0.5226
2	Decision Tree	8	0.7312	0.6563	0.6273	0.6401
3	Decision Tree	10	0.7412	0.6594	0.6450	0.6514

Pentru a observa influenta hiperparametrilor asupra performantei, a fost variat parametrul `max\_depth` al arborelui de decizie. Acest hiperparametru controleaza adancimea maxima a arborelui.

Un arbore prea putin adanc poate produce underfitting, deoarece nu poate invata suficiente reguli. Un arbore prea adanc poate produce overfitting, deoarece poate invata prea multe detalii specifice setului de antrenare.

	Model	max_depth	Accuracy	Precision	Recall	F1
0	Decision Tree	3	0.6245	0.3934	0.4378	0.3850
1	Decision Tree	5	0.6557	0.5698	0.5333	0.5226
2	Decision Tree	8	0.7312	0.6563	0.6273	0.6401
3	Decision Tree	10	0.7412	0.6594	0.6450	0.6514
4	Logistic Regression	-	0.7609	0.6809	0.6605	0.6684

gistic Regression a fost folosit ca model suplimentar pentru clasificare. Acest model este potrivit pentru clasificare deoarece estimeaza probabilitatea apartenentei unui exemplu la fiecare clasa.



Cel mai bun model de clasificare a fost ales pe baza valorii F1-score. Aceasta metrica este mai potrivita decat simpla acuratete deoarece setul de date are clase dezechilibrate.

Pentru modelul ales a fost realizata matricea de confuzie, pentru a observa clasele unde apar cele mai multe erori de clasificare.

Matricea de confuzie arata comparatia dintre clasele reale si clasele prezise. Valorile de pe diagonala principala reprezinta predictii corecte, iar valorile din afara diagonalei reprezinta erori de clasificare.

	Model	Alpha	Train MAE	Val MAE	Train MSE	Val MSE	Train R2	Val R2
0	Linear Regression	-	6642.83	6645.52	1.272640e+08	1.245427e+08	0.9	0.9019

Pentru sarcina de regresie, modelul baseline a fost Linear Regression. Acesta incearca sa estimeze salariul printr-o combinatie liniara a atributelor de intrare.

Performanta modelului a fost evaluata folosind MAE, MSE si R2. MAE si MSE masoara eroarea de predictie, iar R2 indica proportia variatiei explicate de model.

	Model	Alpha	Train MAE	Val MAE	Train MSE	Val MSE	Train R2	Val R2
0	Linear Regression	-	6642.83	6645.52	1.272640e+08	1.245427e+08	0.9000	0.9019
1	Ridge Regression	0.1	6643.11	6645.79	1.272683e+08	1.245612e+08	0.9000	0.9019
2	Ridge Regression	1	6645.33	6648.06	1.272688e+08	1.245648e+08	0.9000	0.9019
3	Ridge Regression	10	6668.84	6671.89	1.273142e+08	1.246381e+08	0.9000	0.9019
4	Ridge Regression	100	6981.83	6974.50	1.304057e+08	1.278937e+08	0.8976	0.8993

Pentru imbunatatirea regresiei a fost folosit Ridge Regression, care adauga regularizare L2. Regularizarea penalizeaza coeficientii foarte mari si poate reduce riscul de overfitting.

A fost variat parametrul `alpha`, care controleaza intensitatea regularizarii. Valori mai mari ale lui `alpha` inseamna o penalizare mai puternica asupra coeficientilor.

	Model ales	Alpha	Train MSE	Val MSE	Train R2	Val R2
0	Linear Regression	-	1.272640e+08	1.245427e+08	0.9	0.9019

Tabelul prezinta modelul de regresie cu cea mai mica eroare pe setul de validare.